

✓ Clase 23 — Datos, sesgos y cómo aprende una IA

Diplomado IA Aplicada al Diseño · UDD · 2026 · Prof. Darío Osorio

Ejecuta las celdas en orden. Donde diga # TU TURNO, modifica lo indicado.

Objetivos del notebook

1. Cargar y explorar un dataset real (reseñas en español).
2. Detectar visualmente balance de clases y valores faltantes.
3. Identificar un sesgo posible.

Archivos necesarios: `Clase_23_dataset_resenas_es.csv` (súbelo a Colab junto con este notebook, ver Paso 1).

✓ Paso 0 — Instalación

```
!pip install -q pandas matplotlib seaborn
print("Listo.")
```

Listo.

✓ Paso 1 — Subir y cargar el dataset

Este notebook usa un dataset local (`Clase_23_dataset_resenas_es.csv`), preparado por el profesor: 1000+ reseñas de productos en español, con distribución realista (desbalanceada) y algunos valores faltantes / duplicados a propósito, para que los detectes tú.

Antes de ejecutar la siguiente celda: `Archivo → Subir cuaderno` ya lo hiciste; ahora sube también el CSV con el icono de carpeta (📁) a la izquierda → `Subir a almacenamiento de sesión` → selecciona `Clase_23_dataset_resenas_es.csv`.

```
import pandas as pd
```

```
# Dataset local (no depende de descargas externas ni de conexión inestable en vivo)
df = pd.read_csv("ScreenTime vs MentalWellness.csv")
```

```
print(f"Cargadas {len(df)} filas")
print(f"Columnas disponibles: {df.columns.tolist()}")
df.head()
```

Cargadas 400 filas

Columnas disponibles: ['user_id', 'age', 'gender', 'occupation', 'work_mode', 'screen_time_hours', 'work_screen_hours', 'leisure_screen_hours', 'sleep_hours', 'sleep_quality']

	user_id	age	gender	occupation	work_mode	screen_time_hours	work_screen_hours	leisure_screen_hours	sleep_hours	sleep_quality
0	U0001	33	Female	Employed	Remote	10.79	5.44	5.35	6.63	
1	U0002	28	Female	Employed	In-person	7.40	0.37	7.03	8.05	
2	U0003	35	Female	Employed	Hybrid	9.78	1.09	8.69	6.48	
3	U0004	42	Male	Employed	Hybrid	11.13	0.56	10.57	6.89	
4	U0005	28	Male	Student	Remote	13.22	4.09	9.13	5.79	

✓ Paso 2 — Ver primeras filas

```
df[['stress_level_0_10', 'screen_time_hours']].head(15)
```

	stress_level_0_10	screen_time_hours
0	9.3	10.79
1	5.7	7.40
2	9.1	9.78
3	10.0	11.13
4	10.0	13.22
5	10.0	9.83
6	6.1	6.02
7	5.4	6.21
8	1.6	6.28
9	10.0	9.37
10	8.8	9.87
11	4.6	4.96
12	10.0	12.55
13	6.3	7.86
14	10.0	9.07

▼ Paso 3 — Balance

```
import matplotlib.pyplot as plt

x = df['screen_time_hours']
y = df['mental_wellness_index_0_100']

plt.figure(figsize=(8,5))


plt.scatter(x, y, alpha=0.6)

plt.title("Tiempo de pantalla vs. bienestar mental")
plt.xlabel("Tiempo de pantalla (horas)")
plt.ylabel("Índice de bienestar mental (0-100)")

plt.tight_layout()
plt.show()

# Correlación entre ambas variables
correlacion = x.corr(y)

print(f"Correlación entre tiempo de pantalla y bienestar mental: {correlacion:.2f}")
```



✓ Paso 4 — Sesgos

```
import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(9,5))


sns.boxplot(
    x='occupation',
    y='mental_wellness_index_0_100',
    data=df
)

plt.title("Bienestar mental según ocupación")
plt.xlabel("Ocupación")
plt.ylabel("Índice de bienestar mental (0-100)")

plt.xticks(rotation=20)
plt.tight_layout()
plt.show()

print("Cantidad de registros por ocupación:")
print(df['occupation'].value_counts())

print("\nBienestar mental promedio por ocupación:")
print(
    df.groupby('occupation')['mental_wellness_index_0_100']
      .mean()
      .sort_values()
)
```



Cantidad de registros por ocupación:

✓ Paso 5: Valores faltantes

occupation
Employed 207
Student 107
Self-employed 45

```
print("Valores faltantes por columna:\n")
print(df.isnull().sum())

print("\nRegistros duplicados:", df.duplicated().sum())

print("\nIDs de usuario duplicados:", df['user_id'].duplicated().sum())
```

```
Employed      20.188406
Self-employed 20.759718
Retired       31.578571
Unemployed    34.274074
Name: mental_wellness_index_0_100, dtype: float64
gender        0
occupation    0
work_mode     0
screen_time_hours  0
work_screen_hours  0
leisure_screen_hours  0
sleep_hours    0
sleep_quality_1_5  0
stress_level_0_10  0
productivity_0_100  0
exercise_minutes_per_week  0
social_hours_per_week  0
mental_wellness_index_0_100  0
Unnamed: 15    400
dtype: int64
```

Registros duplicados: 0

IDs de usuario duplicados: 0

TU TURNO — bitácora