

Clase 26 — Hugging Face: el ecosistema de la IA

Diplomado IA Aplicada al Diseño • UDD • 2026 Profesor: Darío Osorio Fecha: Jueves 27 de agosto de 2026 · 18:30–21:00 hrs Modalidad: **online sincrónico** · Unidad 3 · Sesión 5 de 10 · **Propuesta D**

Ejercicios prácticos

Herramienta: huggingface.co (cuenta gratis).

Ejercicio 1 — Explorar el Hub

- ✓ Crear cuenta en huggingface.co (gratis).
- ✓ Ir a Models. Filtrar por:
 - Task: Text Generation.
 - Language: Spanish.
 - Sort by: Most Downloads.
- ✓ Elegir 3 modelos que te llamen la atención. Para cada uno anotar en la bitácora:
 - Nombre completo.
 - Autor / Organización.
 - Tamaño (número de parámetros).
 - Licencia.
 - Una limitación declarada en la model card.

Modelo 1

The screenshot shows the Hugging Face interface for the model 'meta-llama / Llama-3.2-1B-Instruct'. The top navigation bar includes 'Hugging Face', a search bar, and links to 'Models', 'Datasets', 'Spaces', 'Docs', and 'Pricing'. The model's name is displayed with a 'like' button (1.6k) and a 'Follow' button (85.3k). Below the name are tags for 'Text Generation', 'Transformers', 'Safetensors', 'PyTorch', '8 languages', 'llama', 'facebook', 'meta', 'llama-3', and 'conversational'. There are also links for 'Eval Results', 'text-generation-inference', 'arxiv:2204.05149', 'arxiv:2405.16406', and 'License: llama3.2'. The 'Model card' tab is selected, showing a 'You need to agree to share your contact information to access this model' message. The 'LLAMA 3.2 COMMUNITY LICENSE AGREEMENT' is displayed, with a release date of September 25, 2024. The 'Downloads last month' graph shows 6,417,690 downloads. The 'Safetensors' section shows 'Model size: 1B params' and 'Tensor type: BF16'. The 'Inference Providers' section shows 'Featherless AI' as the selected provider. A banner at the bottom says 'Run 15,000+ Models Instantly'.

Nombre completo: Llama 3.2-1B-Instruct

Identificador en Hugging Face: meta-llama/Llama-3.2-1B-Instruct


Autor / Organización: meta-llama

Tamaño: 1B params.

Licencia: llama3.2

Una limitación declarada: Uso de cualquier forma que infrinja las leyes o regulaciones aplicables (incluidas las leyes de cumplimiento comercial). Uso de cualquier otra forma prohibida por la Política de uso aceptable y la Licencia de la comunidad Llama 3.2. Uso en idiomas distintos a los explícitamente mencionados como compatibles en esta tarjeta modelo.

Modelo 2



Nombre completo: NVIDIA-Nemotron-3-súper-120B-A12B-NVFP4

Identificador en Hugging Face: nvidia/NVIDIA-Nemotron-3-Super-120B-A12B-NVFP4

Autor / Organización: nvidia

Tamaño: 67B params.

Licencia: nvidia-nemotron-open-model-license

Una limitación declarada: Uso de memoria: A pesar de activar solo 12 mil millones de parámetros por token (12B activos de 120B totales), la carga total del modelo en memoria requiere hardware de clase empresarial/servidor (típicamente 80 GB+ de VRAM).

Modelo 3

The screenshot shows the Hugging Face interface for the model **bigscience/bloomz-560m**. At the top, there's a navigation bar with links to Models, Datasets, Spaces, Docs, and Pricing. Below this, the model's header includes its name, a like button (138), a follow button, and a link to the BigScience Workshop (1.36k). A row of tags indicates the model's capabilities: Text Generation, Transformers, PyTorch, TensorBoard, Safetensors, bigscience/xP3, 46 languages, and bloom. Below the tags, there are links to Eval Results (legacy), text-generation-inference, arxiv:2211.01786, and the license: bigscience-bloom-rail-1.0. A secondary navigation bar includes links to the Model card, Files, xet, Metrics, and Community (15). On the right, there are buttons for Deploy, Copy to bucket, and Use this model. The main content area features a large black banner with the BLOOMZ & mT0 logo. To the right of the banner, a graph shows the number of downloads last month (941,280). Below the graph, the Safetensors section displays the model size (0.6B params) and tensor type (F16). The Inference Providers section indicates that the model is not yet deployed by any provider. At the bottom right, a model tree shows 280 adapters and 33 finetunes for this model.

bigscience / **bloomz-560m** like 138 Follow BigScience Workshop 1.36k

Text Generation Transformers PyTorch TensorBoard Safetensors bigscience/xP3 46 languages bloom

Eval Results (legacy) text-generation-inference arxiv:2211.01786 License: bigscience-bloom-rail-1.0

Model card Files xet Metrics Community 15 Deploy Copy to bucket Use this model

Downloads last month
941,280

Safetensors
Model size 0.6B params Tensor type F16
Files info

Inference Providers
Text Generation
This model isn't deployed by any Inference Provider. Ask for provider support

Model tree for bigscience/bloomz-560m
Adapters 280 models
Finetunes 33 models

Table of Contents

1. [Model Summary](#)
2. [Use](#)
3. [Limitations](#)
4. [Training](#)
5. [Evaluation](#)
6. [Citation](#)

Nombre completo: bloomz-560m

Identificador en Hugging Face: bigscience/bloomz-560m

Autor / Organización: bigscience

Tamaño: 0.6B params.

Licencia: bigscience-bloom-rail-1.0


Una limitación declarada: El rendimiento puede variar según la indicación. Para los modelos BLOOMZ, recomendamos dejar muy claro cuándo termina la entrada para evitar que el modelo intente continuarla. Por ejemplo, la indicación " *Traducir al inglés: Je t'aime* " sin el punto (.) al final, puede hacer que el modelo intente continuar la frase en francés. Mejores indicaciones son, por ejemplo, " *Traducir al inglés: Je t'aime.* ", " *Traducir al inglés: Je t'aime. Traducción:* " " *¿Qué es "Je t'aime." en inglés?* ", donde queda claro para el modelo cuándo debe responder. Además, recomendamos proporcionar al modelo tanto contexto como sea posible. Por ejemplo, si quiere que responda en telugu, dígame al modelo, por ejemplo, " *Explique en una frase en telugu qué es la retropropagación en redes neuronales* ".

Ejercicio 2 — Probar modelos vía Spaces


- ☒ Ir a Spaces. Filtrar por: Text-to-Image.
- ☒ Elegir 2 Spaces populares.
- ☒ Probar con el mismo prompt en los 2.

Prompt: Un celular en el centro de una mesa de comedor de madera rústica, estilo cálido y hogareño

Space 1: FLUX.1



Space 2: Z Image Turbo



- ☒ Comparar outputs, velocidad, calidad.

Ambas herramientas fueron sumamente expeditas, logrando generar y desplegar la imagen final en menos de un minuto. Sin embargo, la diferencia determinante radicó en la interpretación del prompt y la fidelidad del resultado.

Por un lado, **Flux.1** desvió la atención del elemento principal expresado en la instrucción, priorizando la composición de un comedor y una mesa de estilo rústico en lugar de enfocar el celular con sus atributos estéticos solicitados. En contraste, **Z-Image** comprendió con mayor precisión la esencia del pedido, ubicando el objeto central de forma idónea y entregando una calidad visual superior y alineada con la idea inicial. En definitiva, aunque ambos espacios destacan por su rapidez, Z-Image ofrece un apego semántico y un nivel de detalle sustancialmente mejor.

- ☒ Repetir con Text-Generation (probar 2 LLMs open source vía Spaces).

Prompt: Learn about gardening

Space 1: BananaMind-Arena

The screenshot shows the BananaMind-Arena interface on HuggingFace Spaces. The browser address bar shows 'huggingface.co'. The page title is 'BananaMind-Arena' with a 'like' button showing 7 likes. The interface includes a 'Prompt' input field with the text 'Learn about gardening'. To the right of the prompt is a 'Max new tokens' slider set to 128, with a range from 16 to 512. Below the prompt is a 'Battle' button. The interface is divided into two columns for Model A and Model B. Model A's output is a detailed gardening tip about watering, while Model B's output is information about wildflowers. At the bottom, there are four buttons for voting: 'A is better', 'Tie', 'Both are bad', and 'B is better'. A footer note states 'Model names stay hidden until you vote.'

Space 2: ChatGPT Prompt Generator

The screenshot shows a web browser at `huggingface.co` displaying the 'ChatGPT Prompt Generator' application. The browser's address bar and tabs are visible at the top. The application title is 'ChatGPT Prompt Generator'. Below the title, a description states: 'This app generates ChatGPT prompts, it's based on a BART model trained on [this dataset](#). Simply enter a persona that you want the prompt to be generated based on.' Below this, there is an input field labeled 'Input a persona, e.g. photographer' containing the text 'Learn about gardening'. To the right of the input field are 'Clear' and 'Submit' buttons. To the right of the input field, the generated prompt is displayed in a box: 'I want you to act as a gardener. I will teach you how to grow vegetables, herbs, herbs and other plants for your garden. You will also be responsible for maintaining the garden. My first request is "I need help growing vegetables and herbs for my garden."' Below the input field, there is an 'Examples' section with two buttons: 'photographer' and 'developer'. At the bottom of the page, there is a footer that reads 'Use via API' and 'Construido con Gradio'.

huggingface.co

Espacios Merve/Generador de indicaciones para ChatGPT como 1.22k Agentes Correr en CERO Obtén PRO

ChatGPT Prompt Generator

This app generates ChatGPT prompts, it's based on a BART model trained on [this dataset](#). Simply enter a persona that you want the prompt to be generated based on.

Input a persona, e.g. photographer

Learn about gardening

Clear Submit

Prompt

I want you to act as a gardener. I will teach you how to grow vegetables, herbs, herbs and other plants for your garden. You will also be responsible for maintaining the garden. My first request is "I need help growing vegetables and herbs for my garden."

Examples

photographer developer

Use via API · Construido con Gradio

Ambos Spaces fueron rápidos, aunque BananaMind Arena tardó ligeramente más en procesar la respuesta, éste ofreció respuestas informativas directas, pero con inconsistencias. En cambio, ChatGPT Prompt Generator transformó la entrada en un prompt de rol estructurado y preciso de manera inmediata.

Ejercicio 3 — Buscar modelos para tu proyecto (25 min)

Basado en el problema de tu proyecto (heredado de Unidad 2), buscar en HF: - 1 modelo generativo relevante. - 1 modelo analítico relevante. - 1 dataset que podrías usar.

Para cada uno, documentar en tu bitácora: nombre, tarea, licencia, por qué te sirve.

Modelo Generativo

The screenshot shows the Hugging Face interface for the model 'meta-llama/Llama-3.1-8B-Instruct'. The header includes the Hugging Face logo, a search bar, and navigation links for Models, Datasets, Spaces, Docs, and Pricing. The model's name is prominently displayed with a 'like' button (6.84k) and a 'Follow' button (Meta Llama, 85.6k). Below the name are tags for 'Text Generation', 'Transformers', 'Safetensors', 'PyTorch', '8 languages', 'llama', 'facebook', 'meta', 'llama-3', and 'conversational'. There are also links for 'Eval Results', 'text-generation-inference', 'arxiv:2204.05149', and 'License: llama3.1'. The 'Model card' tab is selected, showing a 'You need to agree to share your contact information to access this model' message. The 'LLAMA 3.1 COMMUNITY LICENSE AGREEMENT' is visible, along with the release date (July 23, 2024) and a link to 'Expand to review'. On the right, there's a 'Downloads last month' graph showing 5,644,039 downloads. Below that, the 'Safetensors' section shows 'Model size: 8B params' and 'Tensor type: BF16'. The 'Inference Providers' section lists 'Novita' as a provider. A banner at the bottom right says 'Run 15,000+ Models Instantly'.

Nombre: Llama 3.1-8B-Instruct

Tarea: Generación de textos

Licencia: llama3.1

Por qué sirve: Para redactar los disparadores de conversación adaptados a la mesa de manera fluida y cálida, actuando como el motor generativo de tu aplicación. Tiene un entendimiento sobresaliente del idioma español.

Modelo Analítico

 **Hugging Face**

[Models](#) [Datasets](#) [Spaces](#) [Docs](#) [Pricing](#)



 **bert-base-spanish-wwm-cased** 

 like 79 [Follow](#)  DCC UChile 57

[Fill-Mask](#) [Transformers](#) [PyTorch](#) [TensorFlow](#) [JAX](#) [Spanish](#) [bert](#) [masked-lm](#) [arxiv:7 papers](#)

[Model card](#) [Files](#) [xet](#) [Community](#)

[Deploy](#) [Copy to bucket](#) [Use this model](#)

BETO: Spanish BERT

BETO is a [BERT model](#) trained on a [big Spanish corpus](#). BETO is of size similar to a BERT-Base and was trained with the Whole Word Masking technique. Below you find Tensorflow and Pytorch checkpoints for the uncased and cased versions, as well as some results for Spanish benchmarks comparing BETO with [Multilingual BERT](#) as well as other (not BERT-based) models.

Download

BETO uncased	tensorflow_weights	pytorch_weights	vocab_config
BETO cased	tensorflow_weights	pytorch_weights	vocab_config

Downloads last month
60,964



Inference Providers

 HF Inference...

[Fill-Mask](#) [Examples](#)

Mask token: [MASK]

[Generate](#)

[View Code](#) [Maximize](#)

Model tree for dccuchile/bert-base-spanish-ww...

Adapters	4 models
Finetunes	196 models
Quantizations	1 model

Nombre: BETO Universidad de Chile

Tarea: Clasificación de textos

Licencia: CC BY 4.0

Por qué sirve: Al ser entrenado en Chile, es ideal para analizar el texto de retroalimentación de los usuarios y clasificar si la dinámica de la mesa fue divertida, tensa o nostálgica sin perder el contexto cultural.

Dataset

The screenshot shows the Hugging Face dataset page for 'empathetic_dialogues_llm' by user 'Estwld'. The page includes a search bar, navigation links (Models, Datasets, Spaces, Docs, Pricing), and a header with the dataset name and a 'like' button. Below the header, there are filters for Tasks (Text Generation), Modalities (Text), Formats (parquet), Languages (English), and Size (10K - 100K). There are also tags for 'empathetic', 'ED', and 'dialogue', and libraries for 'Datasets', 'pandas', and 'Croissant'. The license is 'apache-2.0'. The page has tabs for 'Dataset card', 'Data Studio', 'Files', and 'Community'. The 'Dataset card' tab is active, showing a 'Dataset Viewer' with a table of data. The table has columns for 'conv_id', 'situation', 'emotion', and 'conversations'. The 'conversations' column contains JSON objects with 'content' and 'emotion' fields. On the right side, there are buttons for 'Copy to bucket' and 'Use this dataset', and a 'Downloads last month' section showing 445 downloads. There are also input fields for 'Number of rows' (24,850) and 'Total file size' (7.74 MB). At the bottom, there is a section for 'Models trained or fine-tuned on Estwld/...' with a link to 'mradermacher/Hermes_2_Pro_Mis...'.

Dataset: Estwld/empathetic_dialogues_llm

Tasks: Text Generation Modalities: Text Formats: parquet Languages: English Size: 10K - 100K

Tags: empathetic ED dialogue Libraries: Datasets pandas Croissant + 1 License: apache-2.0

Dataset card Data Studio Files Community

Dataset Viewer Auto-converted to Parquet API Embed Duplicate Data Studio

Split (3)
train · 19.5k rows

Search this dataset

conv_id	situation	emotion	conversations
hit:0_conv:1	I remember going to the fireworks with my best...	sentimental	[{ "content": "I remember..."
hit:1_conv:2	i used to scare for darkness	afraid	[{ "content": "it feels lik...
hit:1_conv:3	I showed a guy how to run a good bead in welding...	proud	[{ "content": "Hi how are yo...

Downloads last month 445

Number of rows: 24,850

Total file size: 7.74 MB

Models trained or fine-tuned on Estwld/...

mradermacher/Hermes_2_Pro_Mis...

Nombre: Empathetic_dialogues_llm

Tarea: Clasificación de textos

Licencia: Apache 2.0

Por qué sirve: Es una base de datos en español con miles de conversaciones cotidianas etiquetadas según 32 emociones distintas (como orgullo, alegría, tristeza o nostalgia). Sirve de base para que el asistente de Sobremesa entienda qué tipo de preguntas detonan qué emociones y cómo guiar la conversación con empatía.